胡 楷

男 | 湖北武汉 | 中共党员 | 23 岁(2003 年 06 月) | 硕士 1 年级在读
☎：(+86)183-7218-2131　　✉：365157138@qq.com
主要研究方向：人工智能及大模型安全　　GitHub：https://github.com/wushirenhk
期望城市：武汉 | 实习时间：6 个月，可立即到岗

教育背景

武汉大学(985)	电子信息专业(推免)	硕士	2025.09-2027.06
中国海洋大学 (985)	智能科学与技术专业(排名 2/45|前 5%)	本科	2021.09-2025.06

项目经历

DeepSeek-LLM-7B-Chat 医疗领域 LoRA 微调　　**项目负责人**　　2025.09-2025.11

基于 DeepSeek-7B-Chat 大模型，通过 LoRA 轻量化微调技术，定制适配医疗领域的多轮对话与开放式交互场景，优化模型在医疗问答场景下的回复效果。

- 开发工具：Python、PyTorch、Transformers、PEFT、ModelScope
- 使用技术：LoRA、LLM 微调、多轮对话建模、模型权重合并数据增广，具体如下：
  1. 数据预处理：清洗并标准化医疗多轮对话数据集，适配大模型微调格式；2. 模型微调：分别针对医疗多轮对话、开放式交互场景设计 LoRA 微调策略，优化模型医疗问答能力；3. 模型融合：合并 LoRA 微调权重与基座模型，生成可独立部署的完整模型；4. 效果验证：搭建推理流程，测试模型医疗对话回复的准确率与合理性，准确率达 91.2%；5. 部署适配：封装 ModelScope 模型加载方法，简化模型调用。

Learn Claude Code 轻量级多智能体系统构建　　**项目负责人**　　2025.12-2026.03

从 0 到 1 构建类 Claude Code 轻量级智能体系统，逐步实现从单智能体交互到多智能体自主协作的完整流程。

- 开发工具：Python、LLM API、bash、JSONL
- 针对上下文溢出、大任务低效、多智能体协作混乱等难点，优化智能体系统的全流程构建：
  1. 利用三层上下文压缩策略，解决了长会话场景下上下文容量限制问题，支撑无限会话能力；
  2. 利用任务拆分+后台线程异步执行，解决了大任务处理低效与流程阻塞问题，提升智能体持续思考能力；
  3. 利用 JSONL 异步通信协议+任务自主认领+目录隔离，解决了多智能体协作混乱与任务冲突问题。

论文

DG-DA: A Dual Gradient Attack on Knowledge Distillation of LLMs (CCF-A ICML **在投)**　　**第一作者**

主导提出针对大语言模型 LLM 知识蒸馏的双梯度攻击方法 DG-DA，通过双梯度扰动机制对教师模型输出分布进行任务差异化扰动，在保障学生模型主流 NLP 任务性能的同时，显著破坏对齐任务的知识迁移。设计一阶近似与课程自适应策略降低计算开销、提升攻击隐蔽性，经多数据集与模型验证，攻击效果显著且具备强迁移性。

Physical Prompt Injection Attacks on Large Vision–Language Models (CCF-A TDSC **在投)**　　**共同第一作者**

提出首个面向 VLM 的黑盒物理提示注入攻击 PPIA，通过筛选有效视觉提示+时空注意力引导的环境化部署实现攻击。在 10 款主流模型的仿真与真实物理实验中攻击成功率达 98%，多物理条件下鲁棒性优异。

专业技能

计算机基础：熟练掌握计算机数据结构，了解操作系统，熟练使用 Linux，具备 Linux 下 AI 开发部署实际经验；
编程语言：熟练掌握 Python，熟悉 C++/C，具备高性能 AI 基础设施开发与性能优化能力；
AI 框架与技术：熟悉 PyTorch、TensorFlow、CUDA 加速、LangChain 等 AI 框架与工具，熟悉大模型 API 调用，具备大模型蒸馏、微调经验及 Prompt 筛选与优化经验。

其他

英语水平：**CET-6：580**　　学生工作：任研究生党支部副支书；曾任计算机类 5 班班长、职业发展委员
荣誉奖项："华为杯"中国研究生数学建模竞赛**国家级二等奖**、全国大学生机器人大赛 RoboMaster **国家级一等奖**、**国家奖学金(前 1%)**、全国大学生数学建模竞赛**省级一等奖**、武汉大学研究生优秀新生**一等奖**学金等